

De conteos crudos a PCA

Explicación matemática paso a paso, con un ejemplo real

Este documento recorre, paso a paso, la transformación matemática que sufre la matriz de conteos de GO terms antes de entrar en la PCA (`interactive_go_tree.run_pca_on_relative_abundance`). Cada paso se explica con su fórmula y se ilustra con un ejemplo real extraído directamente de la matriz de datos -- no son números inventados.

Especie de ejemplo (elegida por tener el `Total_prots` más cercano a la mediana del dataset, para que sea representativa y no un caso extremo):

`Raphidocelis_subcapitata` (`Total_prots` = 13383)

Dos columnas GO de esa misma especie, elegidas para ilustrar los dos casos posibles:

- GO con conteo = 0 -> `GO:0000006`
"high-affinity zinc transmembrane transporter activity"
- GO con conteo típico (cercano a la mediana de valores no-cero de esta especie)
-> `GO:0000022` (conteo real = 2)
"mitotic spindle elongation"

Pasos cubiertos:

1. Pseudo-count (+1)
2. $\log(\text{count}+1)$
3. CLR (centrado por fila)
4. `StandardScaler` (z-score por columna)
5. `TruncatedSVD` (proyección final)

Matriz real usada: 1542 especies x 21623 columnas GO
(tras el filtro de columnas raras, `colsum > 5`).

Paso 1 — Pseudo-count (+1)

$$count' = count + 1$$

El siguiente paso es un logaritmo, y $\log(0)$ no está definido. Sumar 1 a cada conteo (incluyendo los que ya son > 0) evita ese problema sin necesitar un caso especial para los ceros -- simplemente se desplaza toda la escala en 1 antes de tomar logaritmos.

	GO:0000006	GO:0000022
count	0	2
count + 1	1	3

Importante: un conteo real de 0 se convierte en 1, y un conteo real de 1 también se convertiría en 2 -- ambos casos siguen siendo distinguibles después del pseudo-count. Lo que nunca ocurre es que un 0 y un 1 originales terminen indistinguibles entre sí.

Paso 2 — Logaritmo

$$\log(count + 1)$$

El logaritmo comprime los valores grandes y expande los valores pequeños: reduce la influencia desproporcionada de GO terms con conteos extremos (colas largas) y hace la distribución mucho más simétrica -- es el paso que más reduce el skew (ver el informe de distribuciones, [pca_transform_steps.png](#)).

	GO:0000006	GO:0000022
count + 1	1	3
$\log(count+1)$	0.0000	1.0986

Nótese que $\log(1) = 0$: todo GO ausente (conteo real 0) queda con el mismo valor (0) en esta etapa, sea cual sea la especie -- la diferenciación entre especies para ese GO vendrá del paso siguiente (CLR), que centra por la media de cada fila.

Paso 3 — CLR (centered log-ratio)

$$CLR_i = \log(count_i + 1) - \overline{\log(count + 1)}_{fila}$$

Se resta, a cada valor de la fila (especie), la media de $\log(count+1)$ de esa misma fila -- calculada sobre TODAS las columnas GO de esa especie, no solo las dos del ejemplo. Esto elimina el efecto de "tamaño" por especie (especies con más proteínas anotadas tienen sistemáticamente valores más altos en casi todas las columnas): tras el CLR, lo que queda es cuánto se desvía cada GO term de lo que es "típico" para esa especie, no su magnitud absoluta.

Media real de $\log(count+1)$ en la fila de *Raphidocelis_subcapitata* (calculada sobre las 21623 columnas GO de esa especie):

media_fila = 0.4132

	GO:0000006	GO:0000022
$\log(count+1)$	0.0000	1.0986
- media_fila	- 0.4132	- 0.4132
= CLR	-0.4132	0.6854

El GO ausente (conteo 0) queda con un valor NEGATIVO tras el CLR (por debajo de la media de la fila) en vez de en un "0 universal" compartido por todas las especies -- esto es justamente lo que elimina el efecto de escala por especie.

Paso 4 — StandardScaler (z-score por columna)

$$z = \frac{CLR - \mu_{col}}{\sigma_{col}}$$

Ahora se estandariza cada COLUMNA (cada GO term) por separado: se resta la media de esa columna (a través de todas las especies) y se divide por su desviación estándar. Así todos los GO terms entran en la PCA con la misma escala -- sin esto, GO terms con más varianza natural dominarían la PCA independientemente de si son biológicamente relevantes.

Media y desviación estándar reales de cada columna, calculadas sobre las 1542 especies del dataset:

GO:0000006: media_col = -0.0690 sd_col = 0.7178

GO:0000022: media_col = 0.6576 sd_col = 1.0929

	GO:0000006	GO:0000022
CLR	-0.4132	0.6854
- media_col	- -0.0690	- 0.6576
/ sd_col	/ 0.7178	/ 1.0929
= z-score	-0.4796	0.0254

Paso 5 — TruncatedSVD (proyección final)

$$PC_k = Z \cdot v_k$$

Este último paso ya no actúa columna a columna: cada especie es un vector fila completo de z-scores (uno por cada GO term retenido), y se proyecta sobre las direcciones (v_1 , v_2 , ...) que capturan la mayor varianza conjunta entre especies. Por eso no se puede mostrar como una operación sobre una sola celda -- el PC1/PC2 de una especie depende de TODAS sus 21623 columnas GO a la vez, ponderadas por los "loadings" (v_k) de cada GO term.

Resultado real para la especie de ejemplo, *Raphidocelis_subcapitata*:

PC1 = -58.46

PC2 = -39.95

Varianza explicada por todo el dataset en esta proyección:

PC1 = 42.0% PC2 = 7.1%

Cómo evoluciona el dataset completo

Estadísticos globales (todas las especies x todas las columnas GO) en cada etapa

Etap	min	max	mean	mediana	sd
0. Conteo crudo	0.00	57382.00	5.02	0.00	74.39
1. + pseudo-count (+1)	1.00	57383.00	6.02	1.00	74.39
2. log(count+1)	0.00	10.96	0.58	0.00	1.00
3. CLR (centrado por fila)	-1.58	9.42	-0.00	-0.41	0.98
4. StandardScaler (z-score)	-10.79	22.27	0.00	-0.07	1.00

Lectura rápida:

- El rango (min-max) del conteo crudo es enorme (miles de unidades de diferencia).
- Tras el log, ese rango se comprime radicalmente.
- Tras el CLR, la media global queda prácticamente en 0 (centrado por fila).
- Tras StandardScaler, la sd global es 1 por construcción -- cada columna aporta el mismo peso de partida a la PCA.